



HAVACILIKTA YAPAY ZEKA ARAŞTIRMALARI TOPLULUĞU

PROJE: TUSAŞ Lift Up

GÖREV: Tabular Transformer

TARİH: 20.03.2026

TANIM

Giriş ve Motivasyon

Uçuş performans parametrelerinin doğru ve hızlı biçimde kestirilmesi, modern havacılık sistemlerinde kritik bir mühendislik gereksinimidir. Havacılık performans kestirimi; hız rejimi (Mach), brüt ağırlık, konfigürasyon/sürükleme durumu (drag index) ve çevresel/operasyonel koşulların, motor yakıt tüketimi ile aerodinamik sürükleme bileşenleri üzerinden birbirine bağlandığı kuvvetli biçimde doğrusal olmayan bir problem sınıfıdır. Bu değişkenler arasındaki ilişkiler çoğu zaman yalnızca doğrusal olmayan değil, aynı zamanda rejime bağlı ve bölgesel karakter gösteren fiziksel yapılardır. Dolayısıyla problem, yalnızca belirli çalışma noktalarındaki performans verilerinin saklanması ibaret olmayıp, bu düğüm noktaları arasında kalan operasyon koşulları için güvenilir tahmin üretilmesini de gerektirmektedir.

Tarihsel olarak bu ihtiyaç, performans veri tabanları, lookup tabloları ve bu tablolar üzerinde uygulanan interpolasyon yöntemleri ile karşılanmıştır. Bu yaklaşımın uzun yıllardır yaygın biçimde kullanılmasının temel nedenleri; deterministik davranış sergilemesi, açıklanabilir olması ve gömülü sistemlerde uygulanabilirlik açısından güçlü bir çerçeve sunmasıdır. Nitekim NATOPS performans el kitaplarında “Drag Index System” kapsamında uçuş performans grafiklerinin drag index formatında verildiği, belirli brüt ağırlık ve drag index değerleri için grafikten specific range ve total fuel flow bilgilerinin okunduğu, ayrıca fuel flow eğrileri arasında interpolasyon yapılarak ara değerlerin elde edilebildiği açıkça belirtilmektedir. Bu durum, geleneksel tablo-temelli yaklaşımın operasyonel havacılıkta yerleşik ve mühendislik açısından güvenilir bir referans yöntem olduğunu göstermektedir.

Bununla birlikte, tablo temsili ayrıkt düğümler aracılığıyla sürekli bir fiziksel yüzeyin yaklaşık gösterimini sunduğundan, özellikle transonik bölge gibi eğriliğin yüksek olduğu rejimlerde doğrusal ya da çoklu doğrusal interpolasyon hatayı büyütebilmektedir. Tablo çözünürlüğünün artırılması bu hatayı azaltabilse de, bu kez bellek gereksinimi, erişim maliyeti ve gerçek-zamanlı uygulama yükü artmaktadır. Böylece doğruluk ile hesaplama/bellek maliyeti arasında belirgin bir ödünleşim ortaya çıkmaktadır. Bu bağlamda temel mühendislik sorusu, performans bilgisinin daha kompakt, daha genellenebilir ve donanım-kısıtlı ortamlarda çalıştırılabilir bir model ile temsil edilip edilemeyeceğidir.

Tabular veri problemlerinde ağaç tabanlı yöntemler, özellikle de XGBoost, yüksek performansları nedeniyle güçlü bir temel çizgi oluşturmaktadır. Bununla birlikte son yıllarda TabTransformer ve FT-Transformer gibi Transformer tabanlı mimariler, kolonlar arası etkileşimleri öz-dikkat mekanizması aracılığıyla örneğe bağlı olarak öğrenebilmeleri sayesinde tabular mühendislik problemlerinde dikkat çekici bir alternatif olarak öne çıkmıştır.

Öz-dikkat mekanizmasının temel ifadesi olan :

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V \quad (1)$$

yapısı, özellikler arası ilişkilerin bağlama duyarlı biçimde modellenmesini mümkün kılmaktadır. Bu özellik, Mach etkisinin drag index, ağırlık ve diğer operasyonel değişkenlerle birlikte farklı rejimlerde değiştiği havacılık performans verileri açısından anlamlı bir avantaj sunmaktadır.



HAVACILIKTA YAPAY ZEKA ARAŞTIRMALARI TOPLULUĞU

PROJE: TUSAŞ Lift Up

GÖREV: Tabular Transformer

TARİH: 20.03.2026

TANIM

Ancak tabular derin öğrenme literatüründe Transformer tabanlı yöntemlerin her problemde ağaç tabanlı modellere evrensel olarak üstün olduğuna dair kesin bir uzlaşa bulunmamaktadır. Bu nedenle bu çalışmanın amacı, Transformer mimarisini doğrudan üstün kabul etmek değil; havacılık performans verileri için neden anlamlı bir aday model ailesi olduğunu ortaya koymak, bunu XGBoost gibi güçlü bir referans yöntemle adil bir kıyaslama çerçevesinde değerlendirmek ve aynı zamanda modeli PSO ile donanım-farkındalıklı biçimde optimize etmektir. Böyle bir yaklaşım, yalnızca yeni bir model önermeyi değil, aynı zamanda geleneksel ve modern yöntemleri aynı problem üzerinde karşılaştırma imkânı da sunmaktadır. Bu sayede tahmin doğruluğu kadar model boyutu, hesaplama maliyeti ve gömülü ortamlarda uygulanabilirlik gibi pratik ölçütler açısından da hangi yaklaşımın hangi koşullarda daha avantajlı olduğunun şeffaf biçimde incelenmesi mümkün olmaktadır.

Veri ve Problem Tanımı

NATOPS performans dokümantasyonunda specific range ve fuel flow değerleri, drag index ve gross weight ile birlikte çeşitli Mach ve irtifa seviyeleri için grafikler ve tablolar halinde sunulmaktadır. Kullanıcı senaryosunda ilgili grafiğe brüt ağırlık, drag index ve uçuş koşulları ile girilerek fuel flow ve specific range değerleri okunmakta; gerektiğinde eğriler veya düğüm noktaları arasında interpolasyon yapılarak ara çalışma noktaları için planlama verisi üretilmektedir. Bu yapı, proje kapsamında kullanılan Excel veri setlerinin “grafiklerden sayısallaştırılmış performans arama tablosu” niteliğini açıklamaktadır.

Çalışmada kullanılan veri setleri, One_Engine_Data.xlsx ve Two_Engine_Data.xlsx dosyalarından oluşmaktadır. Bu iki dosya, sırasıyla tek motor ve çift motor çalışma modlarına karşılık gelen iki ayrı örneklem uzayı olarak değerlendirilmiştir. Veri setlerinin birlikte ele alınabilmesi ve modelin motor çalışma moduna bağlı davranış farklılıklarını öğrenebilmesi amacıyla, birleştirme aşamasında her gözleme veri kaynağını temsil eden engine_type etiketi eklenmiştir. Böylece model, yalnızca sürekli performans değişkenlerini değil, aynı zamanda operasyon moduna bağlı yapısal farkları da temsil edebilecek şekilde tanımlanmıştır.

Veri setleri birden fazla irtifa seviyesini içermektedir. Tek motor veri setinde Sea Level'dan 35,000 ft'a kadar, çift motor veri setinde ise Sea Level'dan 50,000 ft'a kadar uzanan irtifa katmanları yer almaktadır. Bu nedenle problem, yalnızca tek bir uçuş düzeyi için değil, farklı irtifa rejimlerinde geçerli olacak şekilde ele alınmıştır. İrtifa boyutunun veri setine dahil olması, specific range davranışının yalnızca Mach, gross weight ve drag index ile değil, aynı zamanda atmosferik koşullara bağlı performans değişimleriyle birlikte modellenmesini mümkün kılmaktadır.

Veri temizleme ve standardizasyon aşamasında, farklı sayfalardan ve dosyalardan gelen kayıtların ortak bir yapıya dönüştürülmesi hedeflenmiştir. Bu kapsamda, Mach ve specific range alanlarında ondalık ayırıcı olarak kullanılan virgül işaretleri standart sayısal formata çevrilmiş, irtifa bilgisi tüm kayıtlar için tutarlı bir değişken olarak temsil edilmiş ve iki veri setindeki isimlendirme farkları normalize edilmiştir.

Özellikle Gross Weight alanındaki adlandırma farklılıklarının giderilmesi, birleşik veri yapısının tek bir eğitim hattında kullanılabilmesi açısından gerekli görülmüştür. Bu ön işleme adımlarının deterministik biçimde tanımlanması, eğitim ve çıkarım aşamalarında aynı veri temsiliinin korunması açısından önem taşımaktadır.



HAVACILIKTA YAPAY ZEKA ARAŞTIRMALARI TOPLULUĞU

PROJE: TUSAŞ Lift Up

GÖREV: Tabular Transformer

TARİH: 20.03.2026

TANIM

Veri kapsamı açısından dikkat çeken bir diğer nokta, iki çalışma modunun aynı irtifa üst sınırına sahip olmamasıdır. Tek motor veri seti 35,000 ft seviyesine kadar uzanırken, çift motor veri seti 50,000 ft seviyesine kadar veri içermektedir. Dolayısıyla üst irtifa bölgelerinde örnek temsili motor konfigürasyonuna göre farklılaşmaktadır. Bu durum, modelin veri yoğunluğu ve genelleme davranışı değerlendirilirken göz önünde bulundurulması gereken bir kapsam özelliği olarak ele alınmalıdır.

Bu veri yapısı altında problem, denetimli öğrenme çerçevesinde çok değişkenli regresyon problemi olarak tanımlanmıştır. Girdi vektörü **x**; irtifa, gross weight, drag index, Mach, fuel flow ve engine_type bileşenlerinden oluşmakta, hedef değişken **y** ise specific range olarak belirlenmektedir. Buna göre model, uçuş koşullarını temsil eden çok boyutlu giriş uzayından performance efficiency göstergesi olan specific range değerine giden aşağıdaki dönüşümü öğrenmektedir:

Buradaki amaç, yalnızca veri tablolarındaki mevcut düğüm noktalarını yeniden üretmek değil; bu çok boyutlu performans uzayında yer alan yeni veya ara çalışma noktaları için de güvenilir, tutarlı ve düşük hatalı kestirimler sağlayabilen bir fonksiyon yaklaşımı geliştirmektir.

$$\hat{y} = f_{\theta}(\mathbf{x}) \quad (2)$$

Mimari Bileşenler

Tabular Transformer yaklaşımı altında iki temel mimari çizgi öne çıkmaktadır: **TabTransformer** ve **FT-Transformer**. TabTransformer, Transformer bloklarını ağırlıklı olarak kategorik değişken gömmeleri üzerinde işleterek bağlamsal kategorik temsiller üretmekte; sayısal değişkenler ise çoğunlukla normalizasyon sonrasında daha doğrudan bir MLP başlığına aktarılmaktadır. Buna karşılık FT-Transformer, hem sayısal hem de kategorik özellikleri ortak bir boyutta token temsiline dönüştürerek tüm kolonları Transformer encoder içinde işlemektedir. Böylece yalnız kategorik değil, sayısal değişkenler arasındaki etkileşimler de öz-dikkat mekanizması üzerinden modellenabilmektedir.

Bu çalışmada kullanılan veri yapısı, büyük ölçüde sayısal özelliklerden oluşmaktadır. Ayrıca problem yalnızca tek bir uçuş düzeyine değil, çoklu irtifa rejimlerine yayılan bir performans yüzeyine karşılık geldiğinden, **Mach, irtifa, gross weight, drag index, fuel flow** ve **engine_type** değişkenleri arasındaki etkileşimlerin birlikte temsil edilmesi gerekmektedir. Bu nedenle, tüm özelliklerin tokenlaştırılarak ortak bir Transformer akışında işlendiği FT-Transformer yaklaşımı, bu problem için birincil aday mimari olarak değerlendirilmiştir.

Katmanlar ve Veri Akışı

Model akışı, ön işleme → tokenizasyon/gömme → Transformer encoder blokları → regresyon başlığı sırasıyla tanımlanmıştır. Ön işleme aşamasında veriler ortak sayısal biçime dönüştürülmekte, eksen ve isimlendirme farklılıkları giderilmekte ve model girdileri tutarlı bir yapıya getirilmektedir. Ardından her özellik, feature tokenizer aracılığıyla ortak boyutta bir token temsiline dönüştürülmektedir. Bu tokenlar Transformer encoder bloklarına verilmekte; burada çok başlıklı öz-dikkat mekanizması ve beslemeli ileri ağ yapısı aracılığıyla kolonlar arası ilişkiler öğrenilmektedir. Son aşamada ise elde edilen temsil, regresyon başlığı üzerinden specific range tahminine dönüştürülmektedir.



HAVACILIKTA YAPAY ZEKA ARASTIRMALARI TOPLULUGU

PROJE: TUSAŞ Lift Up

GÖREV: Tabular Transformer

TARİH: 20.03.2026


TANIM

FT-Transformer akışında, sayısal ve kategorik tüm kolonlar aynı temsil uzayına taşınmaktadır. Bu yapı, özellikle uçuş performans verilerinde kritik olan **irtifa-Mach**, **irtifa-fuel flow**, **gross weight-drag index** ve **engine_type-irtifa** gibi örneğe bağlı etkileşimlerin tek bir mimari çerçeve içinde öğrenilebilmesini mümkün kılmaktadır. Böylece model, yalnızca tek tek kolonların etkisini değil, farklı uçuş rejimlerinde değişen ortak davranışları da temsil edebilecek bir yapıya kavuşmaktadır.

FT-Transformer akışı, TabTransformer'dan farklı olarak sayısal kolonları da tokenlaştırarak tüm girdileri ortak bir temsil uzayında işlemektedir. Bu çerçevede her örnek, k adet özellikten oluşan bir kolon kümesi olarak ele alınır ve özellikler sayısal ile kategorik bileşenler halinde ayrıştırılır. Bu çalışmada engine_type kategorik; **irtifa**, **gross weight**, **drag index**, **Mach** ve **fuel flow** ise sayısal özellikler olarak ele alınmaktadır.

İkinci adımda her özellik feature tokenizer aracılığıyla ortak boyutta bir token temsiline dönüştürülür. Böylece tüm kolonlar istiflenerek $T \in \mathbb{R}^{k \times d_{model}}$ biçiminde bir token matrisi elde edilir. Ardından örnek düzeyindeki küresel temsili taşımak üzere diziye bir **[CLS]** token eklenir ve giriş dizisi $Z^{(0)} \in \mathbb{R}^{(k+1) \times d_{model}}$ olarak tanımlanır. Bu yapı, hem tekil kolon etkilerinin hem de kolonlar arası ilişkilerin ortak bir encoder akışında işlenmesini mümkün kılar.

Üçüncü adımda $Z^{(0)}$ ardışık L adet Transformer encoder katmanından geçirilir. Her encoder katmanında çok başlıklı öz-dikkat mekanizması (MHSA) ve beslemeli ileri ağ (FFN) blokları residual bağlantılar ve normalizasyon adımları ile birlikte çalışarak kolonlar arası etkileşimleri öğrenir. Bu süreç sonunda elde edilen son temsil içinde, **[CLS]** token modelin örnek düzeyindeki özet bilgisini taşır. Son aşamada bu temsil, regresyon başlığına verilerek hedef değişken olan **specific range** için tahmin üretilir; böylece model, çok boyutlu uçuş performans girdilerinden çıktısını elde eden bir fonksiyon yaklaşımı olarak çalışır.



Şekil 1: Tabular veriler için özelleştirilmiş Transformer mimarisi akış şeması. Süreç, ham girdi özelliklerinin (MLC boşlukları) bir belirteçleştirici (tokenizer) aracılığıyla vektörleştirilmesiyle başlar. Elde edilen özellik gömmelerine (embeddings) küresel bilgi temsili için bir **[CLS]** belirteci eklenir. Öz-dikkat (self-attention) mekanizmasına sahip Transformer blokları, özellikler arası ilişkileri analiz ederek nihai temsilleri oluşturur. Son aşamada **[CLS]** belirteci üzerinden PSQA (Hasta Spesifik Kalite Güvencesi) başarısızlık olasılığı tahmin edilir.



HAVACILIKTA YAPAY ZEKA ARAŞTIRMALARI TOPLULUĞU

PROJE: TUSAŞ Lift Up

GÖREV: Tabular Transformer

TARİH: 20.03.2026

YÖNTEM

Tokenizasyon Matematiği ve Sayısal/Kategorik Örnekler

FT-Transformer'da feature tokenizer, her özelliği ortak boyutta bir token temsiline dönüştüren temel bileşendir. Genel biçimde, j özelliğe karşılık gelen token aşağıdaki şekilde tanımlanır:

$$T_j = b_j + f_j(x_j), \quad T_j \in \mathbb{R}^{d_{model}} \quad (3)$$

Burada x_j , ilgili özelliğin ham girdisini; $f_j(\cdot)$ ise bu girdiyi d_{model} boyutlu temsil uzayına taşıyan dönüşümü ifade etmektedir. Bu yapı sayesinde sayısal ve kategorik değişkenler, ortak bir token dizisi içinde birlikte işlenebilmektedir.

Sayısal özellikler için token üretimi, skaler girdinin öğrenilebilir bir projeksiyon vektörü ile temsil uzayına taşınması biçiminde yazılabilir. Buna göre sayısal bir özellik için token gösterimi şu şekildedir:

$$T_j^{(num)} = b_j^{(num)} + x_j^{(num)} W_j^{(num)}, \quad W_j^{(num)} \in \mathbb{R}^{d_{model}} \quad (4)$$

Bu ifade, örneğin Mach, irtifa, gross weight veya fuel flow gibi sayısal değişkenlerin, her bir kolon için öğrenilen ayrı bir projeksiyon aracılığıyla sabit boyutlu bir vektöre dönüştürüldüğünü göstermektedir.

Kategorik özellikler için ise token üretimi, ilgili kategoriye karşılık gelen embedding temsiline dayanır. One-hot gösterime eşdeğer biçimde, kategorik bir özellik için token şu şekilde ifade edilebilir:

$$T_j^{(cat)} = b_j^{(cat)} + e_j^T W_j^{(cat)}, \quad W_j^{(cat)} \in \mathbb{R}^{S_j \times d_{model}} \quad (5)$$

Burada e_j , ilgili kategoriye seçen gösterimi; S_j se o özelliğin kategori sayısını ifade etmektedir. Bu yapı, örneğin engine_type değişkeninin embedding tablosu, dan uygun satır seçilerek d_{model} boyutlu bir vektöre dönüştürülmesini sağlamaktadır.

Tüm özellik tokenları bir araya getirildiğinde, model girişini oluşturan token matrisi

$$T = \text{stack}([T_1, \dots, T_k]) \in \mathbb{R}^{k \times d_{model}} \quad (6)$$

şeklinde elde edilir. Böylece her uçuş örneği, kolonların ham değerlerinden oluşan klasik bir tablo satırı olmaktan çıkarak, Transformer encoder tarafından işlenebilecek yapısal bir token dizisine dönüştürülmüş olur.

Bu tokenizasyon yapısı, uçuş performans verilerinde önemli olan kolonlar arası ilişkilerin ortak bir temsil uzayında öğrenilmesini mümkün kılmaktadır. Başka bir ifadeyle model, yalnızca tek tek değişkenlerin etkisini değil; **irtifa-Mach**, **gross weight-drag index** ve **fuel flow-engine_type** gibi etkileşimleri de encoder katmanları içinde birlikte işleyebilecek bir temele sahip olmaktadır.



HAVACILIKTA YAPAY ZEKA ARAŞTIRMALARI TOPLULUĞU

PROJE: TUSAŞ Lift Up

GÖREV: Tabular Transformer

TARİH: 20.03.2026

YÖNTEM

MHSA, FFN, LayerNorm ve Residual Akışı

Transformer encoder katmanının temelinin, **çok başlıklı öz-dikkat** mekanizması (**Multi-Head Self-Attention, MHSA**) ile **beslemeli ileri ağ** (**Feed-Forward Network, FFN**) blokları oluşturmaktadır. Öz-dikkat mekanizmasının temel ifadesi aşağıdaki gibi tanımlanır:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V \quad (7)$$

Bu yapıda Q , K ve V sırasıyla sorgu, anahtar ve değer temsillerini ifade etmektedir.

Öz-dikkat mekanizması, giriş tokenları arasındaki benzerlikleri ağırlıklandırarak her tokenın diğer tokenlardan ne ölçüde bilgi alacağını belirlemektedir. Bu sayede model, kolonlar arası ilişkileri sabit kurallarla değil, örneğe bağlı biçimde öğrenebilmektedir.

MHSA yapısında dikkat işlemi tek bir alt uzayda değil, birden fazla başlık üzerinden paralel olarak yürütülmektedir. h adet başlık kullanıldığında, her başlık için temsil boyutu genellikle $d_k = d_{\text{model}}/h$ olacak şekilde seçilmektedir. Giriş dizisi $Z \in \mathbb{R}^{T \times d_{\text{model}}}$ biçiminde gösterildiğinde, burada $T = k + 1$ olmak üzere her başlık için ayrı doğrusal projeksiyonlar uygulanır ve

$$Q = ZW_Q, \quad K = ZW_K, \quad V = ZW_V \quad (8)$$

ifadeleri elde edilir. Ardından her başlık için dikkat çıktısı hesaplanır ve başlık çıktıları birleştirilerek çıktı projeksiyonu üzerinden yeniden ortak temsil uzayına taşınır. Bu yapı, özellikle uçuş performans verilerinde kritik olan **irtifa-Mach**, **gross weight-drag index** ve **fuel flow-engine_type** gibi etkileşimlerin bağlama duyarlı biçimde temsil edilmesini mümkün kılmaktadır.

MHSA bloğunu izleyen FFN yapısı, her token üzerine ayrı ayrı uygulanan konum bağımsız bir dönüşüm olarak düşünülebilir. Tipik biçimde şu şekilde yazılır:

$$\text{FFN}(z) = W_2 \sigma(W_1 z + b_1) + b_2 \quad (9)$$

burada

$$W_1 \in \mathbb{R}^{d_{\text{model}} \times d_{\text{ff}}}, \quad W_2 \in \mathbb{R}^{d_{\text{ff}} \times d_{\text{model}}} \quad (10)$$

olup, d_{ff} ara katman genişliğini ifade etmektedir. FFN bloğu, attention mekanizmasının kurduğu ilişkileri daha zengin doğrusal olmayan dönüşümler üzerinden işleyerek temsil gücünü artırmaktadır.

Encoder katmanında bu iki blok, Layer Normalization ve residual bağlantılar ile birlikte kullanılmaktadır. Yaygın pre-norm akışında dönüşümler aşağıdaki gibi ifade edilebilir:

$$\begin{aligned} Z' &= Z + \text{Dropout}(\text{MHSA}(\text{LN}(Z))) \\ Z^{\text{new}} &= Z' + \text{Dropout}(\text{FFN}(\text{LN}(Z'))) \end{aligned} \quad (11)$$



HAVACILIKTA YAPAY ZEKA ARAŞTIRMALARI TOPLULUĞU

PROJE: TUSAŞ Lift Up

GÖREV: Tabular Transformer

TARİH: 20.03.2026

YÖNTEM

Bu yapı, öğrenmenin daha kararlı hâle gelmesini sağlamak ve derin katmanlarda bilgi akışının korunmasına yardımcı olmaktadır. Residual bağlantılar, giriş temsilinin tamamen kaybolmasını önlerken; LayerNorm, katmanlar boyunca sayısal ölçeğin dengelenmesine katkı sunmaktadır.

Bu bileşenlerin her biri donanım maliyeti açısından farklı sonuçlar üretmektedir. MHSA bloğu, $T \times T$ boyutlu attention matrisleri nedeniyle yaklaşık $O(T^2)$ ölçeğinde bellek ve zaman maliyeti taşımaktadır. Buna karşılık FFN bloğunda hesaplama yükü çoğunlukla d_{ff} ile ölçeklenen matris çarpımlarında yoğunlaşmaktadır. Bu çalışmada token sayısı, yani kolon sayısı, görece sınırlı olduğundan $O(T^2)$ teriminin pratikte yönetilebilir kalması beklenmektedir. Buna karşılık asıl hesaplama yükünün, özellikle d_{model} ve d_{ff} büyüdükçe FFN ve projeksiyon katmanlarında yoğunlaşacağı değerlendirilmektedir.

Hiperparametreler ve Parametre Sayısı

FT-Transformer mimarisinde ayarlanması gereken temel hiperparametreler; encoder katman sayısı L , dikkat başlığı sayısı h , model temsil boyutu (lr) beslemeli ileri ağ genişliği d_{model} , dropout oranı ve öğrenme oranı d_{ff} olarak tanımlanmıştır. Bu hiperparametreler yalnızca tahmin doğruluğunu değil, aynı zamanda çıkarım gecikmesini ve model boyutunu da doğrudan etkilediğinden, model tasarımında doğruluk-hız-boyut ödünleşiminin birlikte değerlendirilmesi gerekmektedir.

Bu ödünleşimi görünür kılmak amacıyla, model karmaşıklığı yaklaşık parametre sayısı üzerinden ele alınmıştır. Bias terimleri ihmal edildiğinde, bir Transformer encoder katmanında çok başlıklı öz-dikkat projeksiyonları için yaklaşık parametre bulunduğu; $4d_{model}^2$ FFN bloğu için ise yaklaşık $2d_{model}d_{ff}$ parametre gerektiği kabul edilmektedir. Buna göre bir encoder bloğundaki yaklaşık toplam parametre sayısı:

$$P_{block} \approx 4d_{model}^2 + 2d_{model}d_{ff} \quad (12)$$

şeklinde yazılabilir. Toplam model parametre sayısı ise encoder katmanlarının katkısına ek olarak tokenizer ve çıkış başlığını da içerecek biçimde

$$P_{total} \approx L \cdot P_{block} + P_{tokenizer} + P_{head} \quad (13)$$

yaklaşımıyla ifade edilebilir.

Bu formüller, hiperparametrelerin yalnızca temsil gücünü artıran soyut seçimler olmadığını; aynı zamanda doğrudan model boyutu ve hesaplama maliyeti üreten mimari kararlar olduğunu göstermektedir.




HAVACILIKTA YAPAY ZEKA ARAŞTIRMALARI TOPLULUĞU

PROJE: TUSAŞ Lift Up


GÖREV: Tabular Transformer

TARİH: 20.03.2026

YÖNTEM



Şekil 2: Standard bir Transformer Kodlayıcı (Encoder) bloğunun iç yapısı. Şemada, girdi belirteçlerinin (tokens) katman normalizasyonundan (LayerNorm) geçişi, Multi-Head Self-Attention (MHSA) mekanizmasıyla özellikler arası etkileşimlerin ağırlıklandırılması ve Feed-Forward Network (FFN) katmanında doğrusal olmayan (ReLU aktivasyonlu) dönüşümlerin gerçekleştirilmesi gösterilmektedir. Kesikli çizgilerle ifade edilen artık bağlantılar (residual connections), "Add & Norm" adımıyla birleşerek gradyan akışını optimize etmekte ve modelin derin yapısına rağmen eğitim kararlılığını korumaktadır.



Şekil 3: Kategorik ve sürekli (continuous) değişkenlerin eş zamanlı işlendiği uçtan uca Transformer mimarisi. Şemada, kategorik özniteliklerin Column Embedding katmanı üzerinden vektörleştirilerek Multi-Head Attention ve Feed Forward bloklarından oluşan N sayıdaki Transformer katmanına aktarılması gösterilmektedir. Eş zamanlı olarak, sürekli öznitelikler Layer Normalization işleminden geçirilerek Transformer çıktısı ile Concatenation adımıyla birleştirilmektedir. Elde edilen birleşik veri yapısı, nihai tahminin üretilmesi için Multi-Layer Perceptron (MLP) katmanına iletilmekte ve süreç Loss (kayıp) hesaplaması ile tamamlanmaktadır.

Özellikle L , d_{model} ve d_{ff} değerleri büyüdükçe model kapasitesinin artması beklenmekle birlikte, buna paralel olarak çıkarım süresi ve bellek ayak izi de artmaktadır. Bu nedenle PSO tabanlı arama sürecinde "daha büyük model daha iyidir" varsayımı doğrudan geçerli değildir. Edge hedefleri altında uygun çözüm, yalnızca en düşük hata veren değil; aynı zamanda gecikme ve boyut kısıtlarını da karşılayabilen yapı olacaktır.

Bu mimari kararların deney ve dağıtım çıktılarıyla birlikte izlenebilir biçimde kaydedilmesi, ileride gerçekleştirilecek doğrulama, karşılaştırma ve sertifikasyon-benzeri süreçlerde kanıt üretimini kolaylaştırmaktadır. Bu amaçla, veri kaynağından eğitim koşusuna, model artefaktından dağıtım çıktısına kadar uzanan ilişkilerin izlenebileceği bir artefakt şeması önerilmektedir. Toplam model parametre sayısı ise yaklaşık olarak:



HAVACILIKTA YAPAY ZEKA ARAŞTIRMALARI TOPLULUĞU

PROJE: TUSAŞ Lift Up

GÖREV: Tabular Transformer

TARİH: 20.03.2026

YÖNTEM

Model tasarımında yalnızca doğruluk artışı değil, aynı zamanda NVIDIA Jetson sınıfı edge platformlarda yönetilebilir çıkarım gecikmesi, bellek kullanımı ve model boyutu da hedeflenmiştir. Bu nedenle dağıtım hattı, eğitilmiş modelin ONNX formatına aktarılması ve ardından TensorRT ile hedef donanıma uygun engine yapısına dönüştürülmesi üzerinden düşünülmüştür. Ayrıca INT8 nicemleme, model boyutu ve çıkarım gecikmesini azaltabilecek bir seçenek olarak değerlendirilmiştir.

Bu çalışmada model seçimi, yalnızca hata metriğine değil, aynı zamanda edge kısıtlarına da dayalı çok amaçlı bir maliyet fonksiyonu üzerinden yapılmıştır. Bu amaçla normalize edilmiş aşağıdaki minimizasyon maliyeti kullanılmıştır:

$$J(\theta) = w_1 \frac{RMSE(\theta)}{RMSE_{ref}} + w_2 \frac{T_{inf}(\theta)}{T_{ref}} + w_3 \frac{S(\theta)}{S_{ref}}, \quad w_1 + w_2 + w_3 = 1 \quad 14)$$

Kıyaslama sürecinde donanım tarafında raporlanacak temel ölçütler: çıkarım süresi (T_{inf}), tepe bellek kullanımı (Peak RAM), model/engine boyutu ($S(\theta)$) ve hassasiyet modu (FP32, FP16, INT8) olarak belirlenmiştir. Böylece model seçimi yalnızca hata metriklerine göre değil, gerçek dağıtım koşullarındaki çalışma davranışına göre de değerlendirilebilecektir.

FT-Transformer hiperparametre uzayı; L, h, d_{model}, d_{ff} , dropout ve öğrenme oranı gibi ayrık ve sürekli değişkenleri birlikte içermektedir. Bu nedenle hiperparametre araması, klasik grid aramaya göre daha esnek ve daha verimli bir yöntem gerektirmektedir. Bu çalışmada, doğruluk ile birlikte çıkarım süresi ve model boyutunu da dikkate alabilen türev gerektirmeyen bir arama yöntemi olarak Particle Swarm Optimization (PSO) tercih edilmiştir.

PSO'da her parçacık bir hiperparametre vektörünü temsil etmekte, parçacıklar arama uzayında hem kendi geçmiş en iyi konumlarına hem de sürünün en iyi çözümüne göre güncellenmektedir. Ayrık hiperparametreler için ise projeksiyon yaklaşımı kullanılmış; sürekli uzayda güncellenen değerler her iterasyonda geçerli ayrık kümelerle yuvarlanarak mimari tutarlılık korunmuştur.

Burada doğruluk bileşenini $RMSE(\theta)$ çıkarım süresini $T_{inf}(\theta)$ ve model boyutunu $S(\theta)$ temsil etmektedir. Böylece PSO araması, yalnızca en düşük hatayı veren modeli değil; aynı zamanda gecikme ve boyut açısından daha dengeli çözümleri de değerlendirebilmektedir.

Bu sürümde PSO, FT-Transformer için donanım-farkındalıklı hiperparametre optimizasyon aracı olarak ele alınmıştır; amaç, doğruluk-gecikme-boyut ödünleşimi altında en uygun mimari yapılandırmayı belirlemektir.



HAVACILIKTA YAPAY ZEKA ARAŞTIRMALARI TOPLULUĞU

PROJE: TUSAŞ Lift Up

GÖREV: Tabular Transformer

TARİH: 20.03.2026

YÖNTEM

PSO AKIŞI, DENEY TASARIMI VE KIYASLAMA

PSO tabanlı hiperparametre optimizasyonu, bu çalışmada eğitim, doğrulama ve edge ölçüm adımlarını birlikte içeren uçtan uca bir döngü olarak ele alınmıştır. Her iterasyonda parçacıklar geçerli hiperparametre uzayına projekte edilmekte, ilgili FT-Transformer modeli eğitim verisi üzerinde eğitilmekte ve doğrulama kümesinde hata metriği hesaplanmaktadır. Ardından model ONNX formatına aktarılmakta, TensorRT engine oluşturulmakta ve Jetson üzerinde çıkarım süresi, tepe bellek kullanımı ve model boyutu ölçülmektedir. Bu ölçümler üzerinden maliyet fonksiyonu hesaplanmakta, parçacıkların en iyi konumları güncellenmekte ve süreç yinelemeli olarak sürdürülmektedir. Son aşamada seçilen en iyi yapılandırma, yalnızca test kümesi üzerinde nihai raporlama için değerlendirilmektedir.

Adil kıyas için XGBoost ve FT-Transformer modellerinin aynı deney protokolü altında karşılaştırılması esas alınmıştır. Bu kapsamda her iki model için aynı train/validation/test bölmesi, aynı ön işleme adımları, aynı aykırı değer yönetimi ve aynı donanım ölçüm prosedürü kullanılmalıdır. Hiperparametre araması yalnızca validation sonuçlarıyla yönlendirilmeli, test kümesi ise yalnızca nihai performans raporlamasında kullanılmalıdır. Böylece model karşılaştırmasının, protokol farklarından değil doğrudan yöntem farklarından kaynaklanması sağlanmaktadır.

Ön işleme aşamasında ölçekleme ve dönüşüm adımları yalnızca eğitim verisi üzerinde fit edilerek validation ve test kümelerine uygulanmalıdır. Aykırı değer etkisini azaltmak için Fuel Flow ve Specific Range değişkenlerinde p01-p99 aralığına dayalı kırpma uygulanabilir.

Performans değerlendirmesinde RMSE, MAE, R^2 ve MAPE metrikleri birlikte raporlanmalı; edge tarafında ise çıkarım süresi (T_{inf}), tepe bellek kullanımı ve model boyutu dikkate alınmalıdır. Ayrıca XGBoost için ayrılan arama bütçesinin FT-Transformer tarafındaki bütçeyle uyumlu tutulması, kıyasın metodolojik olarak dengeli kalması açısından önemlidir.




HAVACILIKTA YAPAY ZEKA ARAŞTIRMALARI TOPLULUĞU

PROJE: TUSAŞ Lift Up

GÖREV: Tabular Transformer

TARİH: 20.03.2026

YÖNTEM



Şekil 4: Kategorik ve sayısal verilerin işlenmesi için tasarlanmış hibrit Transformer-MLP mimarisi. Şemada, kategorik girdilerin yoğun vektörlere (embeddings) dönüştürülmesinin ardından Transformer bloğu içerisinde öz-dikkat (self-attention) mekanizmasıyla bağlamsal olarak zenginleştirilmesi görülmektedir. Elde edilen bağlamsal temsiller (contextual embeddings), herhangi bir dönüşüme uğramayan sayısal girdilerle birleştirilerek (concatenate) çok katmanlı bir yapay sinir ağına (MLP) iletilmekte ve nihai tahmin çıktısı üretilmektedir.



HAVACILIKTA YAPAY ZEKA ARAŞTIRMALARI TOPLULUĞU

PROJE: TUSAŞ Lift Up

GÖREV: Tabular Transformer

TARİH: 20.03.2026

YÖNTEM

Referanslar

- 1) Y. Gorishniy, I. Rubachev, V. Khrulkov ve A. Babenko, "Revisiting Deep Learning Models for Tabular Data," *Advances in Neural Information Processing Systems*, 2021.
- 2) T. Chen ve C. Guestrin, "XGBoost: A Scalable Tree Boosting System," *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, ss. 785–794, 2016.
- 3) J. Kennedy ve R. Eberhart, "Particle Swarm Optimization," *Proceedings of ICNN'95 - International Conference on Neural Networks*, c. 4, ss. 1942–1948, 1995.
- 4) A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser ve I. Polosukhin, "Attention Is All You Need," *Advances in Neural Information Processing Systems*, 2017.
- 5) X. Huang, A. Khetan, M. Cvitkovic ve Z. Karnin, "TabTransformer: Tabular Data Modeling Using Contextual Embeddings," *arXiv preprint arXiv:2012.06678*, 2020.
- 6) F/A-18E/F Flight Manual: Performance Data for Pilots (A1-F18EA-NFM-200).
- 7) A. Sadou ve E. Njoya, "Applications of Artificial Intelligence in the Air Transport Industry," *Journal of Aerospace Technology and Management*, 2022.
- 8) A. R. Bsoul, "Performance Evaluation of Gradient Boosting vs Transformer-Based Architectures," *Journal of Supercomputing*, 2025.
- 9) A. R. Bsoul, "Performance Evaluation and Error Metrics in Multi-Objective Settings," *Eksploracja i Niezawodność*, 2024.
- 10) S. Peitz ve S. S. Hotegni, "A Survey on Multi-Objective Deep Learning," *arXiv preprint arXiv:2412.01566*, 2024.
- 11) "Lightweight Transformers Edge Deployment Survey," *arXiv preprint arXiv:2601.03290*, 2026.
- 12) Y. Zhang vd., "Multi-Head Self-Attention Mechanisms in High-Dimensional Feature Spaces," *AIAA Journal*, 2023.
- 13) L. Grinsztajn, E. Oyallon ve G. Varoquaux, "Why Do Tree-Based Models Still Outperform Deep Learning on Typical Tabular Data?" *NeurIPS 2022 Datasets and Benchmarks*, 2022.