



HAVACILIKTA YAPAY ZEKA ARAŞTIRMALARI TOPLULUĞU

PROJE: TUSAŞ Lift Up

GÖREV: XGBoost-PSO

TARİH: 01.04.2026

YÖNTEM

1. Problemin Tanımı

Uçuş performans parametrelerinin doğru ve hızlı biçimde tahmin edilmesi, modern havacılık sistemlerinde kritik bir mühendislik gereksinimidir. Bu amaçla performans modellemesi, tarihsel olarak deneysel verilere dayalı arama tabloları (lookup tables) üzerinden yürütülmektedir. Rüzgâr tüneli ve uçuş testlerinden elde edilen veriler, belirli operasyon koşullarına karşılık gelecek şekilde ayırık düğüm noktaları halinde saklanmakta; uçuş sırasında ise bu tablolardan veri okunarak ara değerler interpolasyon yöntemleri ile hesaplanmaktadır. Ancak bu yaklaşım, performans uzayını ayırık bir yapı ile temsil ettiği için sürekli değişen uçuş koşullarını yeterli doğrulukta yansıtmakta sınırlı kalmakta; ayrıca çözünürlüğün artırılması doğrudan bellek ve hesaplama maliyetlerini yükseltmektedir.

Bu bağlamda specific range, irtifa, uçak ağırlığı, Mach sayısı, aerodinamik sürüklenme ve yakıt akışı gibi değişkenlerin doğrusal olmayan etkileşimleri sonucu oluşan çok boyutlu bir çıktı değişkenidir. Söz konusu fonksiyonun analitik olarak kapalı formda ifade edilmesi çoğu durumda mümkün değildir ve farklı operasyon bölgelerinde değişken davranış sergiler. Geleneksel tablolar bu yapıyı yalnızca ayırık örnekler üzerinden temsil edebilmekte ve ara değer tahminini ek sayısal işlemlere bağımlı hale getirmektedir.

Bu çalışmada, specific range problemi klasik tablo tabanlı temsilden çıkarılarak denetimli öğrenme kapsamında çok değişkenli bir regresyon problemi olarak ele alınmıştır. Böylece amaç, yalnızca gözlenen veri noktalarını temsil eden değil, aynı zamanda veri kümesinde bulunmayan ara operasyon koşulları için de genellenebilir ve sürekli tahmin üretebilen bir fonksiyon yaklaşımı geliştirmektir. Bu yaklaşım, özellikle bellek ve işlem kapasitesi kısıtlı sistemlerde performans bilgisinin daha kompakt ve etkin temsil edilmesini mümkün kılmaktadır.

2. Problemin Matematiksel Tanımı

Specific range tahmin problemi, çok değişkenli bir fonksiyon yaklaşımı problemi olarak aşağıdaki biçimde tanımlanabilir:

$$SR = f(x_1, x_2, \dots, x_p) \quad (1)$$

Burada, SR specific range değerini; $x_1, x_2, \dots, x_p$ ise uçuş koşullarını temsil eden giriş değişkenlerini göstermektedir. Bu çalışmada giriş uzayı, irtifa, brüt ağırlık, drag index, Mach sayısı ve yakıt akışı değişkenlerinden oluşmaktadır. Bu değişkenler yalnızca istatistiksel anlamda değil, fiziksel yorum açısından da specific range'in belirleyici bileşenleridir. Dolayısıyla kurulan öğrenme problemi, fiziksel olarak anlamlı bir öznelilik uzayı üzerinde tanımlanmaktadır.

Veri kümesi aşağıdaki gibi formüle edilebilir: $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$ (2)

Burada $\mathbf{x}_i \in \mathbb{R}^p$ giriş vektörünü, $y_i \in \mathbb{R}$ ise corresponding specific range değerini temsil etmektedir. Amaç, gözlenen örneklerden hareketle bilinmeyen gerçek fonksiyon $f(\mathbf{x})$ 'e yakınsayan bir $\hat{f}(\mathbf{x})$ tahminleyicisi elde etmektir. Bu problem, ampirik risk minimizasyonu çerçevesinde aşağıdaki şekilde yazılabilir:

$$\hat{f} = \arg \min_{f \in \mathcal{H}} \frac{1}{N} \sum_{i=1}^N L(y_i, f(\mathbf{x}_i)) \quad (3)$$



HAVACILIKTA YAPAY ZEKA ARAŞTIRMALARI TOPLULUĞU

YÖNTEM

Burada $\mathcal{L}(\cdot)$ kayıp fonksiyonunu, $\mathcal{H}$ ise seçilen model ailesini temsil etmektedir. Regresyon problemlerinde yaygın olarak kullanılan kare kayıp esas alınırsa amaç, gerçek değer ile tahmin edilen değer arasındaki ortalama farkın karesini minimize etmektir. Ancak yalnızca bu kaybı küçültmek yeterli değildir; modelin aşırı karmaşık hale gelmesini önlemek ve yeni gözlemler üzerinde de başarılı kalmasını sağlamak için düzenleme ve hiperparametre optimizasyonu gereklidir.


Bu nedenle problem iki katmanlı olarak ele alınmaktadır. İlk katmanda uygun bir fonksiyon sınıfı seçilmekte, ikinci katmanda ise bu fonksiyon sınıfı içinde hangi model yapısının hem doğruluk hem de sistem kısıtları açısından en uygun sonuç verdiği araştırılmaktadır.

3. XGBoost Algoritmasının Teorik Temelleri

XGBoost, gradient boosting prensibine dayanan ve karar ağaçlarını toplamsal bir model içinde birleştiren güçlü bir ensemble öğrenme yöntemidir. Temel model yapısı aşağıdaki gibidir:

$$\hat{y}_i = \sum_{k=1}^K f_k(\mathbf{x}_i), f_k \in \mathcal{F} \quad (4)$$

Burada her f_k , bir regresyon ağacını; $\mathcal{F}$ ise karar ağaçları uzayını temsil etmektedir. Bu yapı, modelin karmaşık fonksiyonları tek bir kapalı form denklem yerine çok sayıda parçalı karar yapısı ile temsil etmesini sağlar. Özellikle giriş uzayının farklı bölgelerinde farklı davranış gösteren performans fonksiyonları için bu yaklaşım son derece uygundur.



Şekil 1: XGBoost'un toplamsal (additive) modelleme yaklaşımını temsil eder; model başlangıçta sabit bir tahmin ile başlatılır ve her iterasyonda bu tahmini iyileştirmek için yeni bir karar ağacı eklenir. Her ağaç, mevcut modelin yaptığı hataları (residual) öğrenerek bu hataları azaltmaya odaklanır ve çıktısı modele katkı olarak eklenir. Bu sayede model, tek seferde öğrenmek yerine hataları kademeli olarak düzelterek ilerler ve tüm ağaçların çıktılarının toplamı nihai tahmini oluşturur. Bu iteratif ve toplamsal öğrenme süreci, modelin fonksiyon uzayında adım adım güncellenmesini sağlayarak daha doğru ve güçlü tahminlere ulaşmasına imkan verir.

XGBoost'un optimize ettiği genel amaç fonksiyonu aşağıdaki biçimde yazılır:

$$\mathcal{L}(\phi) = \sum_{i=1}^N l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad (5)$$



HAVACILIKTA YAPAY ZEKA ARAŞTIRMALARI TOPLULUĞU

YÖNTEM

Burada ilk terim tahmin hatasını, ikinci terim ise model karmaşıklığını ifade eder. Düzenleştirme terimi genellikle aşağıdaki şekilde yazılır:

$$\Omega(f_k) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \quad (6)$$

Bu ifadede T , ağacın yaprak sayısını, w_j ise ilgili yaprak ağırlıklarını göstermektedir. ve katsayıları, modelin gereksiz derecede karmaşık hale gelmesini engelleyen kontrol parametreleridir. Böylece XGBoost yalnızca eğitim hatasını minimize etmeye odaklanmaz; aynı zamanda modeli sade tutarak daha iyi genelleme yapmasını sağlamaya çalışır.

XGBoost'un klasik gradient boosting yöntemlerinden ayrıldığı en önemli noktalardan biri, optimizasyon sürecinde ikinci dereceden Taylor açılımı kullanmasıdır. Her iterasyonda eklenecek yeni ağacın etkisi şu şekilde yaklaşık olarak yazılabilir:


$$\mathcal{L}^{(t)} \approx \sum_{i=1}^N \left[g_i f_t(\mathbf{x}_i) + \frac{1}{2} h_i f_t^2(\mathbf{x}_i) \right] + \Omega(f_t) \quad (7)$$

Burada g_i , kayıp fonksiyonunun birinci türevini, h_i ise ikinci türevini temsil eder. Bu ikinci türev bilgisi, optimizasyonun yalnızca yönünü değil, yerel eğriliğini de dikkate aldığı için daha kararlı ve daha hızlı bir öğrenme süreci sağlar.

Ağaç yapısının nasıl bölüneceği ise kazanç (gain) fonksiyonu ile belirlenir:

$$\text{Gain} = \frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma \quad (8)$$

Burada G_L , G_R sol ve sağ dala düşen örneklerin gradyan toplamalarını, H_L , H_R ise Hessian toplamalarını göstermektedir. Yalnızca pozitif bilgi kazancı sağlayan bölmeler korunur. Bu da modelin rastgele veya gereksiz şekilde derinleşmesini önler. Başka bir ifadeyle, ağaç yapısı yalnızca istatistiksel olarak anlamlı ayrımlar üzerine kurulur.





HAVACILIKTA YAPAY ZEKA ARAŞTIRMALARI TOPLULUĞU

YÖNTEM

Şekil 2: Bu yapı, XGBoost'ta bir karar ağacının hangi noktadan bölüneceğine karar verme sürecini temsil eder; model, her olası split için veriyi iki alt gruba ayırdığında hatada oluşacak değişimi gradient ve Hessian toplamaları üzerinden hesaplar ve bu değişimi "gain" olarak ölçer. Gain hesabında yalnızca hata azalımı değil, aynı zamanda model karmaşıklığını kontrol eden düzenleme terimleri de dikkate alınır. Daha yüksek gain üreten bölünmeler, veriyi daha anlamlı ve homojen parçalara ayırdığı için tercih edilirken, katkısı düşük olan seçenekler elenir. Bu mekanizma sayesinde ağaç, her adımda en faydalı ayrımı seçerek ilerler ve model genelinde daha düşük hata ve daha dengeli bir öğrenme sağlanır.

4. Specific Range Tahmini İçin Neden XGBoost Kullanılmıştır?

Bu çalışmada XGBoost algoritmasının tercih edilmesinin temel nedeni, ele alınan problemin yapılandırılmış (tabular) veri karakterine sahip olmasıdır. Specific range tahmin problemi, yüksek boyutlu görüntü verisi veya zaman serisi gibi karmaşık veri tiplerinden farklı olarak, her bir gözlemin fiziksel olarak anlamlı bir operasyonel durumu temsil ettiği çok değişkenli bir tabular veri problemidir. Literatürde yapılan kapsamlı karşılaştırmalı çalışmalar, bu tür veri yapılarında ağaç tabanlı yöntemlerin çoğu durumda derin öğrenme modellerine kıyasla daha yüksek performans ve daha iyi genelleme kabiliyeti sunduğunu ortaya koymaktadır. Bunun temel nedeni, ağaç tabanlı modellerin giriş uzayını eşik temelli bölmelere ayırarak doğrusal olmayan ve düzensiz ilişkileri esnek bir şekilde temsil edebilmesidir.

Specific range fonksiyonu da benzer şekilde doğrusal olmayan, bölgesel olarak değişken davranış sergileyen ve değişkenler arası etkileşimlerin belirleyici olduğu bir yapıdadır. Örneğin, aynı Mach sayısı farklı irtifa seviyelerinde farklı performans çıktıları üretirken, benzer yakıt akışı değerleri farklı ağırlık koşullarında farklı specific range sonuçlarına yol açabilmektedir. Bu tür karmaşık etkileşimler, klasik doğrusal modellerle açık biçimde ifade edilmesi zor olan yapılardır. XGBoost, karar ağaçlarının hiyerarşik bölme mekanizması sayesinde bu tür feature interaction yapılarını açıkça tanımlamaya gerek kalmadan öğrenebilmekte ve bu yönüyle mühendislik tabanlı veri setleri için önemli bir avantaj sağlamaktadır.

Bununla birlikte XGBoost'un tercih edilmesinin bir diğer önemli gerekçesi, model karmaşıklığının kontrol edilebilir olmasıdır. Ağaç sayısı, maksimum derinlik, örneklem oranları ve düzenleme katsayıları gibi hiperparametreler aracılığıyla model kapasitesi doğrudan ayarlanabilmektedir. Bu durum, yalnızca yüksek doğruluk elde etmeyi değil, aynı zamanda modelin hesaplama maliyeti ve bellek kullanımı açısından optimize edilmesini de mümkün kılmaktadır. Özellikle kısıtlı donanım kaynaklarına sahip sistemlerde kullanılacak bir model geliştirme hedefi göz önüne alındığında, bu esneklik kritik bir avantaj sunmaktadır. Dolayısıyla XGBoost, hem istatistiksel performans hem de mühendislik uygulanabilirliği açısından dengeli ve uygun bir modelleme yaklaşımı olarak değerlendirilmiştir.

5. Hiperparametre Seçimi Neden Ayrı Bir Optimizasyon Problemidir?

Makine öğrenmesi modellerinde performans, yalnızca algoritmanın yapısına değil, aynı zamanda hiperparametrelerinin uygun seçimine de bağlıdır. XGBoost'ta ağaç sayısı, maksimum derinlik, öğrenme oranı, örneklem oranları ve düzenleme katsayıları gibi hiperparametreler, modelin hem doğruluğunu hem de karmaşıklığını doğrudan etkilemektedir. Bu nedenle hiperparametre seçimi, basit bir ayarlama süreci olmaktan ziyade, model tasarımının merkezinde yer alan bir optimizasyon problemidir.



HAVACILIKTA YAPAY ZEKA ARAŞTIRMALARI TOPLULUĞU

YÖNTEM

Bu problem aşağıdaki genel formda ifade edilebilir:

$$\theta^* = \arg \min_{\theta \in \Theta} J(\theta) \quad (9)$$

Burada θ , hiperparametre vektörünü; Θ , arama uzayını; $J(\theta)$ ise ilgili modelin performansını ölçen maliyet fonksiyonunu temsil etmektedir. Geleneksel yaklaşımlarda bu fonksiyon yalnızca tahmin hatasına dayanmakta, ancak bu durum çoğu zaman yüksek doğruluk karşılığında artan model karmaşıklığı ve hesaplama maliyeti ile sonuçlanmaktadır.

Bu çalışmada ise hiperparametre optimizasyonu, yalnızca hata minimizasyonu olarak değil, aynı zamanda çıkarım süresi ve model boyutu gibi sistem kısıtlarını da içeren çok amaçlı bir problem olarak ele alınmıştır. Böylece hedef, yalnızca en doğru modeli değil, aynı zamanda belirli donanım kısıtları altında en dengeli performansı sunan modeli elde etmektir.

6. Parçacık Sürü Optimizasyonu (PSO)

Parçacık Sürü Optimizasyonu (PSO), sürü zekâsı prensibine dayanan ve çok boyutlu sürekli arama uzaylarında optimum çözüme yakın sonuçlar elde etmek amacıyla geliştirilmiş bir meta-sezgisel optimizasyon algoritmasıdır. Bu yöntemde her aday çözüm, arama uzayında hareket eden bir parçacık olarak temsil edilir. Her parçacık, konum ve hız vektörleri ile tanımlanmakta olup, çözüm uzayındaki konumu ilgili hiperparametre kombinasyonunu ifade etmektedir. Parçacıklar, iteratif süreç boyunca hem kendi geçmiş deneyimlerinden hem de sürünün kolektif bilgisinden yararlanarak arama uzayında güncellenir.

PSO algoritmasının temel güncelleme denklemleri aşağıdaki şekilde ifade edilmektedir:

$$\begin{aligned} \mathbf{v}_i^{t+1} &= w\mathbf{v}_i^t + c_1r_1(\mathbf{p}_i - \mathbf{x}_i^t) + c_2r_2(\mathbf{g} - \mathbf{x}_i^t) \\ \mathbf{x}_i^{t+1} &= \mathbf{x}_i^t + \mathbf{v}_i^{t+1} \end{aligned} \quad (10)$$

Burada $\mathbf{x}_i$ parçacığın konumunu, $\mathbf{v}_i$ hızını, $\mathbf{p}_i$ parçacığın bireysel en iyi çözümünü ve $\mathbf{g}$ sürünün küresel en iyi çözümünü temsil etmektedir. w atalet katsayısı, c_1 bilişsel katsayı ve c_2 sosyal katsayı olarak tanımlanır. Bu parametreler, algoritmanın keşif (exploration) ve yoğunlaşma (exploitation) davranışları arasındaki dengeyi belirleyerek arama sürecinin etkinliğini doğrudan etkiler.

Bu çalışmada PSO'nun tercih edilmesinin temel nedeni, XGBoost hiperparametre uzayının sürekli, çok boyutlu ve değişkenler arası etkileşimler açısından karmaşık bir yapıya sahip olmasıdır. Geleneksel grid search yöntemleri tüm parametre kombinasyonlarını sistematik olarak taradığı için yüksek hesaplama maliyetine sahiptir. Random search ise daha geniş bir arama alanını kapsayabilmesine rağmen, umut vadeden çözüm bölgelerinde yoğunlaşma yeteneği sınırlıdır. Buna karşılık PSO, iyi çözümler etrafında yönelimli bir arama gerçekleştirirken aynı zamanda yeni bölgeleri keşfetmeye devam eden dinamik yapısı sayesinde daha verimli bir optimizasyon süreci sunmaktadır. Bu özellikleri nedeniyle PSO, XGBoost hiperparametre optimizasyonu için uygun ve etkili bir yöntem olarak değerlendirilmiştir.



HAVACILIKTA YAPAY ZEKA ARAŞTIRMALARI TOPLULUĞU

YÖNTEM

7. Çok Amaçlı Maliyet Fonksiyonu

Bu çalışmanın temel katkılarından biri, model optimizasyonunun yalnızca tahmin doğruluğu üzerinden değil, aynı zamanda sistem düzeyindeki performans kriterleri dikkate alınarak gerçekleştirilmesidir. Geleneksel makine öğrenmesi yaklaşımlarında model başarımı çoğunlukla hata metrikleri (örneğin RMSE) üzerinden değerlendirilmekte ve optimizasyon süreci bu tek ölçüte indirgenmektedir. Ancak gerçek zamanlı çalışan mühendislik sistemlerinde, özellikle gömülü ve aviyonik ortamlarda, bir modelin yalnızca doğru olması yeterli değildir; aynı zamanda düşük gecikme süresi ile çalışması ve sınırlı bellek kaynaklarını etkin kullanması gerekmektedir.

Bu doğrultuda, hiperparametre optimizasyon sürecinde kullanılan maliyet fonksiyonu aşağıdaki şekilde tanımlanmıştır:

$$J(\theta) = w_1 \frac{RMSE(\theta)}{RMSE_{ref}} + w_2 \frac{T_{inf}(\theta)}{T_{ref}} + w_3 \frac{S(\theta)}{S_{ref}} \quad (11)$$

Burada $RMSE(\theta)$, modelin tahmin hatasını; $T_{inf}(\theta)$, bir tahminin üretilmesi için geçen ortalama süreyi; $S(\theta)$ ise modelin bellek veya disk üzerindeki boyutunu temsil etmektedir. $RMSE_{ref}$, T_{ref} ve S_{ref} terimleri, farklı ölçekteki bu metriklerin normalize edilmesini sağlayan referans değerlerdir. w_1 , w_2 , w_3 ağırlıkları ise doğruluk, hız ve model boyutu arasındaki göreceli önemi belirlemektedir.

Bu yapı sayesinde optimizasyon süreci, yalnızca istatistiksel olarak en iyi modeli değil, aynı zamanda sistem entegrasyonu açısından en uygun modeli belirlemeye yönlendirilmektedir. Özellikle tahmin doğruluğu ile hesaplama maliyeti arasında kaçınılmaz olan denge, bu çok amaçlı yaklaşım ile açık biçimde modellenmektedir. Böylece elde edilen çözüm, yalnızca teorik olarak değil, pratik uygulama koşulları altında da uygulanabilir nitelik kazanmaktadır.

8. Modelin Geliştirilmesi ve Uygulanması

Bu çalışmada Specific Range tahmini için XGBoost tabanlı bir makine öğrenmesi modeli geliştirilmiştir. Model, One Engine ve Two Engine veri setlerinin birleştirilmesi ile oluşturulan veri üzerinde eğitilmiştir. Her gözlem için motor tipi bilgisi "Engine_Type" değişkeni ile modele dahil edilmiştir.

Veri Ön İşleme

Ham veri üzerinde aşağıdaki işlemler uygulanmıştır:

- Boş ve eksik gözlemlerin temizlenmesi
- Sayısal olmayan değerlerin uygun formata dönüştürülmesi
- "Sea Level" gibi ifadelerin sayısal karşılıklarının atanması
- Sütun isimlerindeki format farklılıklarının giderilmesi
- Aykırı değerlerin Fuel Flow ve Specific Range değişkenleri için %1-%99 quantile aralığında sınırlandırılması

Bu işlemler sonucunda model eğitimi için tutarlı bir veri seti elde edilmiştir.



HAVACILIKTA YAPAY ZEKA ARAŞTIRMALARI TOPLULUĞU

YÖNTEM

Veri Bölme

Modelin performansını doğru değerlendirebilmek için veri seti üçe ayrılmıştır:

- %70 eğitim seti
- %15 doğrulama seti
- %15 test seti

Eğitim seti modelin öğrenmesi için, doğrulama seti hiperparametre optimizasyonu için, test seti ise nihai performans ölçümü için kullanılmıştır.

Model Yapısı (XGBoost)

Tahmin modeli olarak XGBoost regresyon algoritması kullanılmıştır. Model, doğrusal olmayan ilişkileri öğrenebilme kapasitesi ve tabular veri üzerindeki yüksek performansı nedeniyle tercih edilmiştir.

Modelde optimize edilen başlıca hiperparametreler:

- n_estimators (ağaç sayısı)
- max_depth (ağaç derinliği)
- learning_rate (öğrenme oranı)
- subsample, colsample_bytree
- reg_alpha, reg_lambda
- min_child_weight
-

Eğitim sürecinde early stopping uygulanarak aşırı öğrenme (overfitting) engellenmiştir.

Çok Amaçlı Maliyet Fonksiyonu

Model optimizasyonunda yalnızca tahmin doğruluğu değil, aynı zamanda çalışma performansı da dikkate alınmıştır. Bu nedenle aşağıdaki üç kriter birlikte değerlendirilmiştir:

- Tahmin hatası (RMSE)
- Çıkarım süresi (inference time)
- Model boyutu (model size)

Bu metrikler farklı ölçeklerde olduğundan normalize edilerek aşağıdaki maliyet fonksiyonu oluşturulmuştur:

$$J(\theta) = w_1 \frac{RMSE(\theta)}{RMSE_{ref}} + w_2 \frac{T_{inf}(\theta)}{T_{ref}} + w_3 \frac{S(\theta)}{S_{ref}} \quad (12)$$

Bu yapı sayesinde doğruluk ile donanım maliyetleri arasında dengeli bir optimizasyon sağlanmıştır.



HAVACILIKTA YAPAY ZEKA ARAŞTIRMALARI TOPLULUĞU

YÖNTEM

Parçacık Sürü Optimizasyonu (PSO)

Model hiperparametrelerinin belirlenmesi için Parçacık Sürü Optimizasyonu (PSO) algoritması kullanılmıştır. Optimizasyon süreci aşağıdaki şekilde ilerlemektedir:

- Rastgele hiperparametre kombinasyonları oluşturulur
- Her kombinasyon için XGBoost modeli eğitilir
- Model doğrulama seti üzerinde değerlendirilir
- RMSE, çıkarım süresi ve model boyutu hesaplanır
- Bu metrikler maliyet fonksiyonuna dönüştürülür
- PSO algoritması bu geri bildirimleri kullanarak yeni parametreler üretir

Bu süreç iteratif olarak devam eder ve en düşük maliyet değerini veren parametre seti seçilir.

Nihai Model ve Değerlendirme

Optimizasyon sonucunda elde edilen en iyi hiperparametreler ile model, eğitim ve doğrulama veri setlerinin birleşimi üzerinde yeniden eğitilmiştir.

Model performansı test veri seti üzerinde aşağıdaki metriklerle değerlendirilmiştir:

- RMSE
- MAE
- R^2
- MAPE

Ayrıca modelin çıkarım süresi ve model boyutu ölçülerek donanım açısından uygulanabilirliği analiz edilmiştir.

Model Çıktısı

Eğitilen model, ilgili parametreler ve performans bilgileri ile birlikte .pkl formatında kaydedilmiştir. Bu model, verilen uçuş parametreleri için hızlı bir şekilde Specific Range tahmini yapabilmektedir. Bu yapı sayesinde klasik look-up table ve interpolasyon yöntemlerine alternatif olarak, yüksek doğruluk, düşük çıkarım süresi ve optimize edilmiş model boyutu ile donanım açısından verimli bir çözüm sağlamaktadır.

9. Sonuç

Önerilen XGBoost-PSO tabanlı yaklaşım, klasik arama tablosu (lookup table) temelli yöntemlere kıyasla hem modelleme esnekliği hem de sistem verimliliği açısından önemli avantajlar sunmaktadır. Öncelikle, veri temelli modelleme yaklaşımı sayesinde specific range fonksiyonu ayırık düğüm noktaları ile sınırlı kalmamakta, sürekli bir fonksiyon yaklaşımı olarak temsil edilebilmektedir. Bu durum, veri setinde doğrudan bulunmayan ara operasyon noktaları için güvenilir tahminler üretilmesini mümkün kılmakta ve uçuş sırasında karşılaşılan dinamik koşullara daha iyi uyum sağlamaktadır.



HAVACILIKTA YAPAY ZEKA ARAŞTIRMALARI TOPLULUĞU

YÖNTEM

Bunun yanı sıra, performans bilgisinin yüksek çözünürlüklü tablolar yerine parametreleşmiş bir model aracılığıyla temsil edilmesi, bellek kullanımında önemli bir azalma sağlamaktadır. Bu durum, özellikle sınırlı donanım kaynaklarına sahip sistemlerde uygulanabilirliği artırmakta ve modelin gerçek zamanlı ortamlara entegrasyonunu kolaylaştırmaktadır. Çok amaçlı maliyet fonksiyonu ile gerçekleştirilen optimizasyon süreci ise yalnızca tahmin doğruluğunu değil, aynı zamanda çıkarım süresi ve model boyutunu da dikkate alarak sistem düzeyinde dengeli çözümler üretmektedir.

Bu yönüyle önerilen yaklaşım, yalnızca istatistiksel performans açısından değil, aynı zamanda mühendislik uygulanabilirliği açısından da değerlendirilmiş bütüncül bir modelleme çerçevesi sunmaktadır. Bununla birlikte, veri odaklı yöntemlerin başarımı büyük ölçüde kullanılan veri kümesinin kalitesine ve temsil gücüne bağlıdır. Veri setinin kapsamı, dağılımı ve fiziksel anlamlılığı, modelin genelleme kabiliyetini doğrudan etkilemektedir. Ayrıca çok amaçlı optimizasyon sürecinde kullanılan ağırlık katsayılarının seçimi, elde edilen çözümün doğruluk-hız-karmaşıklık dengesi üzerindeki etkisini belirlemektedir.

Sonuç olarak, geliştirilen model, klasik lookup table yaklaşımlarına kıyasla daha esnek, daha kompakt ve sistem entegrasyonu açısından daha uygun bir çözüm sunmaktadır. Elde edilen bulgular, veri temelli modelleme yaklaşımlarının, uçuş performans fonksiyonlarının temsilde hem doğruluk hem de sistem verimliliği açısından etkili bir alternatif oluşturduğunu göstermektedir. Ayrıca çok amaçlı optimizasyon çerçevesi sayesinde modelin yalnızca istatistiksel başarımı değil, aynı zamanda hesaplama maliyeti ve bellek kullanımı gibi mühendislik kısıtları açısından da dengeli bir yapı sunduğu ortaya konmuştur. Bu doğrultuda çalışma, havacılık performans modellemesinde veri odaklı ve optimize edilmiş yöntemlerin uygulanabilirliğini somut olarak göstermektedir.

Referanslar

- 1) T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System", *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016.
- 2) J. Kennedy and R. Eberhart, "Particle Swarm Optimization", *Proceedings of the IEEE International Conference on Neural Networks*, 1995.
- 3) K. Song, F. Yan, T. Ding, L. Gao and S. Lu, "A steel property optimization model based on the XGBoost algorithm and improved PSO", *Computational Materials Science*, vol. 174, 2020.
- 4) L. Shang, H. Wang, H. Si, Y. Wang, T. Pan, H. Liu and Y. Li, "Flight Trainee Performance Evaluation Using Gradient Boosting Decision Tree, Particle Swarm Optimization, and Convolutional Neural Network (GBDT-PSO-CNN) in Simulated Flights", *Aerospace*, vol. 11, no. 5, 2024.
- 5) A. V. Lakra, S. Jena and K. Mishra, "Optimizing XGBoost Hyperparameters for Credit Scoring Classification using Weighted Cognitive Avoidance Particle Swarm", *IEEE Access*, early access.
- 6) B. Qolomany, M. Maabreh, A. Al-Fuqaha, A. Gupta and D. Benhaddou, "Parameters Optimization of Deep Learning Models using Particle Swarm Optimization", *IEEE International Conference*, 2017.
- 7) Y. V. R. N. Pawan, K. B. Prakash, S. Chowdhury and Y.-C. Hu, "Particle swarm optimization performance improvement using deep learning techniques", *Multimedia Tools and Applications*, vol. 81, 2022.