LIFT UP SANAYİ ODAKLI LİSANS BİTİRME PROJESİ
ARA DEĞERLENDİRME RAPORU

1. GENEL BİLGİLER

Proje Başlığı	Muharip bir hava aracının performans veri setinin farklı yöntemlerle (Polinom, Yapay Sinir Ağları, Pekiştirmeli Öğrenme vb.) modellenerek kıyaslanması.
Üniversite	Eskişehir Teknik Üniversitesi
Bölüm	Havacılık Elektrik Elektroniği – Bilgisayar Mühendisliği – Endüstri Mühendisliği
Akademik Danışman	Doç. Dr. Aziz KABA
Sanayi Danışmanı	Zeynel Abidin AYDOĞAN
Lisans Öğrencileri	Ahmet Soner GÜLEÇ, Umut ÇÖRDÜK, Ufuk ÖZKAN, Semanur ÜNAL, Enes ABA
Rapor Teslim Tarihi	15.02.2026

İlgili dönemde gerçekleştirilen faaliyetler ile bir sonraki dönemde planlanan çalışmaları kapsayan raporun, Arial 11 punto ile hazırlanarak toplamda 2 sayfayı aşmayacak şekilde sunulması beklenmektedir.

2. PROJE KAPSAMINDA GERÇEKLEŞTİRİLEN ÇALIŞMALAR VE ELDE EDİLEN BULGULAR

Proje konusu hakkında kısaca bilgi verilmesi, ilgili dönem içinde gerçekleştirilen araştırma çalışmaları ve elde edilen bulguların özetlenmesi beklenmektedir.

Proje kapsamında, muharip hava araçlarının aviyonik sistemlerinde uçuş performans verilerinin depolanması amacıyla geleneksel olarak kullanılan arama tablosu (Look-up Table- LUT) yöntemlerinin yarattığı doğruluk kaybı ve yüksek donanım kaynağı tüketimi problemlerinin aşılması hedeflenmektedir. Bu doğrultuda, söz konusu performans verilerinin XGBoost ve Tabular Transformer gibi güncel makine öğrenmesi modelleriyle, kısıtlı endüstriyel gömülü sistemlerde yüksek verimlilikle çalışacak şekilde modellenmesi amaçlanmaktadır. Modellerin, Sürü Zekâsı (Particle Swarm Optimization - PSO) tabanlı meta-sezgisel algoritmalarla optimize edilerek doğruluk, çıkarım hızı ve bellek kullanımı gibi donanım metrikleri açısından geleneksel nümerik yöntemlerle kıyaslanması projenin temel odak noktasını oluşturmaktadır.

İlgili rapor döneminde, projenin temelini oluşturan “Veri Dijitasyonu ve Veri Seti Oluşturma" faaliyetlerine odaklanılmıştır. Başlangıçta öngörülen piksel yoğunluğu eşiğine dayalı geleneksel algoritmaların, havacılık nomografları üzerindeki yoğun ızgara (grid) çizgileri ve çakışan metinler nedeniyle yüksek hata oranlarına sebep olduğu tespit edilmiştir. Bu problemi aşmak ve hedef performans eğrilerini arka plan gürültüsünden izole edebilmek amacıyla, görüntü işleme altyapısı Python ortamına taşınmış ve derin öğrenme (U-Net) tabanlı, uçtan uca çalışan yeni bir yazılım mimarisi geliştirilmiştir. Bu kapsamda öncelikle, derin öğrenme modelini eğitmek için ihtiyaç duyulan binlerce uçak performans grafiğini ve bunlara karşılık gelen maskeleri çok çekirdekli mimariyle otomatik üreten sentetik veri üretim altyapısı kurulmuştur. Görsel bir kullanıcı arayüzü ile desteklenen bu sistem üzerinden üretilen verilerin Eğitim, Doğrulama ve Test alt kümelerine ayrılması da otomatikleştirilmiştir. Oluşturulan bu geniş çaplı veri seti kullanılarak U-Net mimarisi, donanım imkanlarına göre hem yerel iş istasyonlarında hem de bulut tabanlı GPU ortamlarında başarıyla eğitilmiş ve

segmentasyon görevini yerine getiren nihai yapay zekâ modeli elde edilmiştir. Eğitim aşamasının ardından bu model kullanılarak tekil görseller veya çoklu PDF dokümanları üzerindeki hedef eğrileri izole eden bir çıkarım modülü geliştirilmiştir. Ayrıştırılan eğriler üzerindeki sayısal değerler ve koordinat bilgileri, optik karakter tanıma (OCR) entegrasyonu ile otomatik olarak okunmakta ve uygun yapısal veri tablolarına dönüştürülmektedir. Tüm bu sisteminin farklı donanımlarda sorunsuz çalışabilirliğini güvence altına almak için donanım/ortam doğrulama araçları, bulut yedekleme sistemleri ve tüm operasyonel adımların detaylandırıldığı kapsamlı dokümantasyonlar da hazırlanarak projeye kazandırılmıştır. Mevcut durum itibarıyla, karmaşık havacılık grafiklerinden çok boyutlu yapısal nokta bulutları elde etme süreci otomatikleştirilmiş olup, projenin bir sonraki aşaması olan XGBoost ve Tabular Transformer tabanlı modelleme çalışmalarına planlanan takvime uygun şekilde geçiş yapılmıştır.

3. PROJE KAPSAMINDA BİR SONRAKİ DÖNEMDE GERÇEKLEŞTİRİLMESİ PLANLANAN ÇALIŞMALAR

Proje kapsamında bir sonraki dönem içinde gerçekleştirilmesi planlanan araştırma faaliyetlerine ilişkin detaylı planın açıklanması beklenmektedir. Bir sonraki proje döneminde mevcut çalışmalardan farklı bir yaklaşım uygulanacaksa bu durum gerekçeleriyle birlikte belirtilmelidir.

Başarıyla tamamlanan "Veri Dijitasyonu ve Veri Seti Oluşturma" aşamasından elde edilen ve yüksek doğruluk oranına sahip veri seti kullanılarak, projenin temelini oluşturan "Modelleme, Optimizasyon ve Donanım Performans Analizi" safhalarına geçilmesi planlanmaktadır. Bu doğrultuda ilk olarak, U-Net mimarisi ve entegre karakter tanıma sistemleriyle sayısallaştırılan çok boyutlu F-18 uçuş performans verileri (irtifa, brüt ağırlık, sürükleme indeksi ve Mach numarası gibi girdiler ile spesifik menzil, yakıt akışı gibi çıktılar) istatistiksel ön işleme ve normalizasyon adımlarından geçirilecektir. Hazırlanan bu veri seti üzerinde, geleneksel Arama Tablosu yönteminin yarattığı hafıza yükü ve enterpolasyon hatalarına yenilikçi bir alternatif olarak önerilen XGBoost ile dikkat mekanizması tabanlı derin öğrenme modeli Tabular Transformer'ın kurulumları ve temel eğitimleri gerçekleştirilecektir. Ardından, kurulan bu modellerin tahmin başarımını maksimize etmek ve aşırı öğrenme (overfitting) riskini minimize etmek amacıyla Sürü Zekâsı tabanlı meta-sezgisel optimizasyon algoritmaları devreye alınacaktır. Bu süreçte PSO, modellerin hiperparametre uzayında iteratif olarak global optimum noktaları arayarak en düşük hata oranını (MSE/RMSE) sağlayan parametre setlerini otonom olarak belirleyecektir. Elde edilen optimize edilmiş nihai makine öğrenmesi modelleri, havacılık gömülü sistemlerinin kısıtlı kaynak (düşük güç tüketimi, sınırlı RAM ve gerçek zamanlı işlem gereksinimi) koşullarını simüle etmek üzere endüstriyel Edge AI (Sınır Bilişim) donanımları üzerine entegre edilecektir. Entegrasyon sonrasında algoritmalar; tahmin doğruluğu, milisaniye cinsinden çıkarım gecikmesi ve megabayt cinsinden bellek ayak izi metrikleri üzerinden geleneksel LUT yöntemleriyle kapsamlı bir şekilde kıyaslanacaktır.

Bir sonraki proje döneminde, araştırma önerisinde taahhüt edilen temel hedeflere ve metodolojik çerçeveye sadık kalınacak olup, uygulanacak yegâne farklılık projenin iş paketleri arasındaki efor dağılımında yapılacak stratejik optimizasyondur. Bu durumun temel gerekçesi, ilk dönemdeki veri sayısallaştırma süreçlerinde klasik piksel tabanlı algoritmalar yerine derin öğrenme tabanlı U-Net mimarisinin sisteme entegre edilmesiyle elde edilen veri setinin bütünlüğünün hedeflenenin üzerine çıkmasıdır. Bu başarılı metodoloji sayesinde, tablo verileri üzerinde gerçekleştirilmesi planlanan gürültü giderme ve aykırı değer temizleme operasyonlarına duyulan ihtiyaç azalmıştır. Veri ön işlemeden tasarruf edilen zaman, yapay zekâ modellerinin kısıtlı aviyonik donanımlarda düşük gecikmeyle çalışmasını sağlayacak donanım-yazılım optimizasyonlarına (kuantizasyon, TensorRT) aktarılarak projenin endüstriyel uygulanabilirliği artırılacaktır.